

LAPORAN TEKNIS KOMPREHENSIF

[CuanSelor: Your Partner for Fearless Financial Freedom]

ID Team	CC26 - PSU254
Topik / Domain	Keuangan
Tanggal	30 Mei 2026

Coding Camp 2026
2026

BAB 1 – PENDAHULUAN

1.1 Latar Belakang

Generasi Z (kelahiran 1997–2012) menghadapi tantangan finansial yang semakin kompleks di tengah tekanan inflasi, biaya hidup yang tinggi, dan gaya hidup konsumtif akibat fenomena FOMO. Berdasarkan data OJK tahun 2024, indeks literasi keuangan kelompok usia muda masih tertinggal signifikan dibandingkan tingkat inklusinya, sehingga mendorong pengambilan keputusan finansial yang berisiko tinggi. Hal ini terbukti dari fakta bahwa kelompok Gen Z menyumbang 39,94% dari total pengguna pinjaman *online* di Indonesia pada tahun 2025, sementara rata-rata alokasi pendapatan mereka untuk tabungan hanya mencapai 10,17%.

Di sisi lain, terdapat ancaman longevity risk yang nyata, yaitu risiko seseorang hidup lebih lama dari ketersediaan dananya. Data Sun Life Asia Financial Resilience Index 2025 menunjukkan bahwa 55% responden belum memiliki rencana keuangan jangka panjang, dan hanya 9% yang menyiapkan dana untuk periode lebih dari 10 tahun ke depan. Kondisi ini diperparah dengan fakta bahwa hanya 6% pekerja di Indonesia yang terlindungi oleh dana pensiun formal, dan tanpa intervensi yang tepat, diproyeksikan 100 juta penduduk Indonesia akan jatuh ke dalam kemiskinan di masa tua pada tahun 2038.

Solusi perencanaan keuangan yang ada saat ini pun masih sangat terbatas. Kalkulator investasi konvensional menggunakan pendekatan deterministik statis yang mengabaikan probabilitas mortalitas riil dan variabilitas profil risiko individu, sementara layanan *financial advisor* konvensional masih tergolong mahal dan tidak mudah diakses oleh mahasiswa maupun kalangan muda. Melihat tren bahwa 21% Gen Z kini mulai mengandalkan AI untuk konsultasi keuangan, terdapat urgensi untuk membangun sistem yang mengintegrasikan data aktuarial dan kecerdasan buatan guna memberikan perencanaan finansial yang personal, akurat, dan mudah diakses.

1.2 Problem Statement

Generasi Z di Indonesia menghadapi kesenjangan antara kebutuhan perencanaan keuangan jangka panjang dan akses terhadap solusi yang memadai. Rendahnya alokasi tabungan Gen Z yang hanya sekitar 10,17% dari pendapatan (Research Institute, 2019) menunjukkan pola pengelolaan keuangan yang belum optimal. Kondisi ini diperparah oleh tingginya ketergantungan pada produk utang konsumtif, di mana Gen Z menyumbang 39,94% dari total pengguna PayLater di Indonesia (IdScore, 2025), mengindikasikan bahwa pengeluaran lebih diprioritaskan daripada pembangunan aset jangka panjang.

Di sisi lain, solusi perencanaan keuangan yang tersedia saat ini belum mampu menjawab kebutuhan segmen ini secara efektif. Kalkulator keuangan konvensional menggunakan pendekatan deterministik statis yang mengabaikan variabel mortalitas, profil risiko individu, dan kondisi ekonomi lokal, sehingga menghasilkan proyeksi yang tidak akurat. Sementara itu, layanan financial advisor konvensional masih tergolong mahal dan tidak mudah diakses oleh kalangan muda dan mahasiswa.

Oleh karena itu, dibutuhkan sistem berbasis AI yang mampu memberikan rekomendasi perencanaan dana pensiun dan investasi secara personal, tervalidasi secara aktuarial, dan dapat diakses oleh pengguna *non-expert* melalui platform digital.

1.3 Tujuan & Sasaran

Tujuan Analisis:

- Membangun model *deep learning* untuk klasifikasi profil risiko pengguna dan model *machine learning* untuk prediksi inflasi sebagai dasar proyeksi dana pensiun.
- Membangun platform web dengan dashboard proyeksi, rekomendasi investasi, perhitungan dana pensiun, dan chatbot LLM yang dapat diakses pengguna *non-expert* secara *real-time*.
- Menghasilkan rekomendasi alokasi instrumen investasi yang personal dan sesuai kondisi ekonomi lokal berdasarkan profil risiko pengguna.

1.4 Pertanyaan Penelitian (Research Questions)

1. Bagaimana CuanSelor dapat membantu Gen Z memahami profil risiko mereka dan membuat keputusan investasi yang lebih tepat?
2. Bagaimana platform CuanSelor dapat memberikan pengalaman perencanaan keuangan yang mudah dipahami dan digunakan oleh pengguna *non-expert*?
3. Bagaimana proyeksi dana pensiun CuanSelor menghasilkan estimasi yang lebih personal dan realistis dibandingkan kalkulator konvensional yang menggunakan asumsi statis?

1.5 Ruang Lingkup (Scope)

In Scope:

- Model *deep learning* untuk klasifikasi profil risiko pengguna
- Model ML untuk prediksi inflasi Indonesia
- Analisis tren kenaikan upah historis per sektor (10 tahun)
- Data historis *return* IHSG dan obligasi sebagai referensi investasi
- Perhitungan aktuarial menggunakan Tabel Mortalitas Indonesia 2023
- Platform web terintegrasi dengan dashboard, rekomendasi, dan chatbot LLM

Out of Scope:

- Integrasi dengan rekening bank atau transaksi investasi nyata
- Prediksi *return* investasi menggunakan ML
- Instrumen investasi di luar IHSG dan obligasi
- Penggantian layanan *financial advisor* berlisensi resmi

BAB 2 – PEMAHAMAN DATA (DATA UNDERSTANDING)

2.1 Sumber Data

Proyek ini menggunakan enam sumber data utama yang seluruhnya bersifat publik dan dapat diverifikasi, sebagaimana dirangkum pada tabel berikut:

Data	Sumber	Periode	Kegunaan
Tabel Mortalitas Penduduk Indonesia (TMPI) 2023 — harapan hidup, qx , px per usia dan jenis kelamin	TMPI 2023	2023	Dasar perhitungan aktuarial proyeksi dana pensiun
Rata-rata upah pekerja per sektor (17 sektor)	BPS & Rakernas	2015–2025	Perhitungan tren pertumbuhan gaji (<i>salary growth</i>)
Inflasi CPI umum tahunan	BPS	2015–2025	Pelatihan model prediksi inflasi jangka panjang
Inflasi CPI sektoral (makanan, kesehatan, pendidikan)	BPS	2015–2025	Perhitungan <i>multiplier</i> inflasi sektoral pada proyeksi kebutuhan pensiun
Data historis indeks IHSG	Stooq	2015–2025	Perhitungan <i>expected return</i> instrumen investasi saham
Data historis <i>yield</i> obligasi 10 tahun Indonesia	Stooq	2015–2025	Perhitungan <i>expected return</i> instrumen investasi obligasi

2.2 Deskripsi Dataset

Ringkasan statistik dataset sebelum preprocessing:

Nama	Sumber	Periode	Baris	Kolom	Ukuran	Keterangan
IHK Umum 2015–2019	BPS	2015–2019	152	61	44.2 KB	IHK umum 90 kota, basis 2012=100
IHK Umum 2020–2023	BPS	2020–2023	91	49	30.9 KB	IHK umum 90 kota, basis 2018=100
IHK Umum 2024–2026	BPS	2024–2026	39	29	8.3 KB	IHK umum 38 provinsi, basis 2022=100
IHK Makanan 2015–2019	BPS	2015–2019	152	61	54.3 KB	IHK kelompok bahan makanan, basis 2012=100
IHK Makanan 2020–2023	BPS	2020–2023	91	49	39.9 KB	IHK kelompok makanan & minuman, basis 2018=100
IHK Makanan 2024–2026	BPS	2024–2026	39	29	10.0 KB	IHK kelompok makanan & minuman, basis 2022=100
IHK Kesehatan 2015–2019	BPS	2015–2019	152	61	54.3 KB	IHK kelompok kesehatan, basis 2012=100
IHK Kesehatan 2020–2023	BPS	2020–2023	91	49	40.0 KB	IHK kelompok kesehatan, basis 2018=100
IHK Kesehatan 2024–2026	BPS	2024–2026	151	29	39.4 KB	IHK kelompok kesehatan, basis 2022=100
IHK Pendidikan 2015–2019	BPS	2015–2019	152	61	52.2 KB	IHK kelompok pendidikan, basis 2012=100

IHK Pendidikan 2020–2023	BPS	2020–2023	91	49	39.8 KB	IHK kelompok pendidikan, basis 2018=100
IHK Pendidikan 2024–2026	BPS	2024–2026	151	29	31.2 KB	IHK kelompok pendidikan, basis 2022=100
Obligasi Pemerintah 10 Tahun (10Y IDY)	Stooq	2013–2026	137	5	4.7 KB	Data bulanan yield obligasi: Open, High, Low, Close
Indeks IHSG	Stooq	2010–2026	197	6	8.9 KB	Data bulanan harga IHSG: Open, High, Low, Close, Volume
Rata-rata Upah per Sektor	BPS & Rakernas	2015–2026	18	13	4.0 KB	Data tahunan upah 17 sektor industri Indonesia
Tabel Mortalitas Penduduk Indonesia 2023	TMPI 2023	2023	113	21	15.1 KB	Data aktuarial per usia: qx, px, harapan hidup, A/E ratio 2018–2022 untuk laki-laki dan perempuan

2.3 Eksplorasi Data Awal (EDA)


2.3.1 Distribusi Data

Eksplorasi distribusi dilakukan terhadap data CPI (umum dan sektoral), *return* IHSG, *yield* obligasi, dan mortalitas menggunakan histogram, boxplot, dan *time series plot*.


CPI Umum dan Sektoral (data sebelum preprocessing): Saat visualisasi *time series* dilakukan pada data mentah yang disambung langsung antar periode, ditemukan anomali yang mencolok pada seluruh seri CPI baik umum maupun sektoral (makanan, kesehatan, pendidikan). Nilai YoY tercatat terjun hingga -24% (CPI Umum), -30% (Makanan), -18% (Kesehatan), dan -20% (Pendidikan) di sekitar Januari 2020 dan Januari 2024. Pada boxplot, nilai-nilai ini muncul sebagai pencilan berat di kuartil bawah. Anomali ini teridentifikasi bukan sebagai kondisi ekonomi riil, melainkan artefak dari perbedaan skala antar sumber data BPS dengan tahun dasar berbeda. Terdapat juga data yang bolong pada CPI Sektor Makanan pada November dan Desember 2024

Return IHSG (2010–2025): Distribusi right-skewed (mean ~6.9%, std ~13.1%), dengan nilai negatif ekstrem riil pada tahun krisis (2008, 2015, 2018, 2020).


Yield Obligasi 10Y & Mortalitas: Tidak ditemukan anomali. Distribusi keduanya konsisten dengan pola yang diharapkan.



Gambar 1. Distribusi variabel utama



Gambar 2. Anomali dan perbandingan observasi



Gambar 3. Distribusi inflasi YoY per sumber data

2.3.2 Missing Values & Anomali

A. Analisis Missing Values

Audit nilai kosong (*missing values*) dilakukan pada seluruh data mentah sebelum proses pembersihan. Terdapat dua jenis *missing values* yang teridentifikasi, yaitu kekosongan observasi faktual dan missing secara struktural:

1. **index_value** pada CPI Sektor Makanan:

Ditemukan kekosongan data faktual (2 baris observasi) pada bulan November dan Desember 2024.

Penyebab: Kemungkinan besar terjadi akibat keterlambatan rilis

Penanganan: Karena sifat data *time-series* indeks harga yang kontinu (dan hanya kosong dalam rentang pendek), dilakukan imputasi berbasis interpolasi linear pada tahap *Data Preparation* (**Bab 3.1**).

B. Analisis Anomali


Berdasarkan visualisasi **time series** pada tahap eksplorasi awal, ditemukan anomali berupa "deflasi ekstrem" yang terjadi secara serentak pada CPI Umum maupun seluruh CPI Sektoral (Makanan, Kesehatan, Pendidikan).

Pada data mentah sebelum pra-pemrosesan, nilai inflasi YoY tercatat terjun bebas hingga -24% untuk CPI Umum, dan mencapai puncaknya di angka -30% pada sektor makanan. Anomali tajam ini terlokalisasi di dua titik waktu spesifik: pergantian tahun 2019 ke 2020, dan 2023 ke 2024.

Penyebab Anomali: Anomali ini bukanlah fenomena ekonomi riil, melainkan distorsi struktural/artefak statistik akibat pergantian tahun dasar (*base year reset*) perhitungan Indeks Harga Konsumen oleh BPS. Publikasi BPS menggunakan tiga standar skala yang berbeda:

1. Periode 2015–2019 menggunakan tahun dasar 2012=100 (level indeks relatif tinggi, misal: ~139 pada akhir 2019).
2. Periode 2020–2023 menggunakan tahun dasar 2018=100 (indeks di-reset kembali ke baseline ~104 pada awal 2020).
3. Periode 2024–2026 menggunakan tahun dasar 2022=100 (indeks kembali di-reset ke ~105 pada awal 2024).

Ketika seri data dengan skala dasar berbeda ini digabungkan secara mentah, formula kalkulasi YoY menafsirkan selisih drastis dari indeks 139 (Desember 2019) ke indeks 104 (Januari 2020) sebagai suatu deflasi besar-besaran. Anomali struktural ini wajib diharmonisasikan sebelum masuk ke dalam model Monte Carlo. Proses harmonisasi (*chain-linking*) didokumentasikan sepenuhnya pada **Bab 3.2** Penanganan Outlier & Anomali.



Gambar 4. Anomali dan periode *exclude*


2.3.3 Korelasi Antar Variabel

Analisis korelasi Pearson dilakukan terhadap variabel inflasi (umum dan sektoral), return investasi IHSG, dan yield obligasi pemerintah 10 tahun (OB10Y) pada periode 2016–2025. Untuk menghindari distorsi statistik dari kondisi ekonomi ekstrem (black swan event), analisis ini mengeksklusi window COVID-19 (Maret 2020 – Desember 2021).

Berdasarkan Heatmap Korelasi, ditemukan beberapa pola hubungan struktural antar variabel makroekonomi:

A. Korelasi Inflasi Sektoral terhadap Inflasi Umum:

1. Sektor Pendidikan ($r \approx 0.58$) dan Kesehatan ($r \approx 0.53$): Keduanya menunjukkan korelasi positif moderat terhadap inflasi umum. Hal ini konsisten secara teoretis karena struktur biaya di sektor pendidikan (SPP, uang pangkal) dan kesehatan (tarif faskes, obat-obatan) cenderung merespons inflasi inti domestik dan kebijakan fiskal negara.
2. Sektor Makanan ($r \approx 0.45$): Memiliki korelasi yang lebih rendah terhadap inflasi umum dibandingkan dua sektor lainnya. Ini mengindikasikan bahwa pergerakan harga makanan memiliki komponen independen yang sangat kuat, didorong oleh faktor eksogen seperti siklus panen musiman, cuaca (El Nino/La Nina), dan volatilitas harga komoditas pangan global.
3. Korelasi Inflasi Umum terhadap Yield Obligasi 10Y ($r \approx 0.44$): Terdapat korelasi positif moderat. Hubungan ini mencerminkan mekanisme transmisi kebijakan moneter Bank Indonesia: ketika inflasi umum merangkak naik, bank sentral cenderung mengetatkan likuiditas (menaikkan BI Rate) untuk meredam inflasi, yang secara langsung mendorong yield obligasi pemerintah bergerak naik di pasar sekunder.
4. Korelasi Inflasi Umum terhadap Return IHSG ($r \approx -0.19$): Ditemukan korelasi negatif lemah. Hal ini sejalan dengan temuan empiris pasar modal bahwa inflasi yang terlalu tinggi cenderung menekan sentimen pasar ekuitas dalam jangka pendek (bulanan), karena meningkatkan ekspektasi suku bunga dan biaya modal perusahaan.
5. Korelasi Antar Sektor Inflasi: Korelasi antar sektor penyusun relatif rendah (Makanan vs Kesehatan $r \approx 0.30$; Makanan vs Pendidikan $r \approx 0.25$). Hal ini menunjukkan bahwa pemodelan simulasi Monte Carlo untuk kebutuhan pensiun harus memperlakukan laju pertumbuhan biaya di masing-masing sektor secara independen (*sector-specific multipliers*), karena pergerakan harganya tidak sepenuhnya sinkron.



Gambar 5. Korelasi antar variabel dan lag korelasi

2.4 Data Dictionary

Data dictionary dapat diakses melalui [data_dictionary.md](#)

BAB 3 – PERSIAPAN DATA (DATA PREPARATION)

Jelaskan setiap langkah preprocessing yang dilakukan, alasan pemilihan teknik, dan dampaknya terhadap data.


3.1 Penanganan Missing Values & Outlier

Teknik yang digunakan dan alasannya:

Kolom **index_value** pada data mentah CPI Sektor Makanan (November-Desember 2024) yang mengalami gap kekosongan diisi menggunakan teknik interpolasi linear. Teknik ini dipilih karena data indeks harga BPS merupakan data deret waktu kontinu (time-series). Brockwell & Davis (2002) merekomendasikan interpolasi linear untuk mengestimasi missing values berjarak pendek pada data ber-tren yang memiliki kontinuitas antar waktu. Sementara itu, missing values struktural pada 12 baris pertama (hasil fungsi `pct_change(12)`) dibuang (listwise deletion) untuk menghindari bias matematis pada perhitungan (Sterne et al., 2009).

Sebelum imputasi (Skala Asli BPS - Base 2022): Index Value November 2024 = NaN, Desember 2024 = NaN.

Sesudah imputasi (Skala Asli BPS - Base 2022): Index Value November 2024 = 108.40, Desember 2024 = 110.13 (mengisi gap secara geometris dan mulus menuju data Januari 2025).



Gambar 6. Penanganan *missing values*

Metode deteksi outlier dan anomali dilakukan menggunakan inspeksi visual distribusi dan time-series plot yang mengungkap dua anomali berbeda dengan perlakuan yang spesifik:

1. Penanganan Anomali Struktural (Data CPI Umum & Sektoral):

Deteksi: Ditemukan lompatan nilai jatuh ke bawah (deflasi fiktif hingga -30% YoY) secara periodik. Anomali teridentifikasi sebagai perubahan tahun dasar BPS (base year shift dari 2012 ke 2018 dan 2022), bukan sebagai fenomena inflasi riil.

Penanganan: Harmonisasi data menggunakan transformasi *Chain-Linking*. Setiap data dengan tahun dasar baru dikalikan dengan rasio indeks pada bulan persinggungan.

Reasoning: Metode ini dipilih karena chain-linking adalah standar utama dari lembaga statistik internasional (IMF, Eurostat) guna menjahit deret waktu yang berbeda skala (base year) tanpa merusak struktur dan tren inflasi historis aslinya (Diewert, 2010).


2. Penanganan Outlier Riil (Return IHSG):

Metode Deteksi: Menggunakan rentang interkuartil atau Interquartile Range (IQR) dengan aturan batas $1.5 \times IQR$ ($Q1 - 1.5 \times IQR$ dan $Q3 + 1.5 \times IQR$).

Penanganan: Data outlier (nilai ekstrem di bawah batas bawah) tidak dihapus (*retained*) dan tidak di-cap.

Reasoning: Dalam pasar ekuitas riil, kejatuhan pasar secara tiba-tiba (*market crash*) bukanlah anomali yang harus dibuang, melainkan risiko fundamental yang berekor tebal (*fat-tail risk*). Membiarkan nilai ekstrem ini tetap masuk ke dalam CSV akan membuat kalibrasi mean dan standard deviation pada model simulasi di *investment.py* menjadi jauh lebih realistis. Ini mencerminkan risiko nyata pasar modal Indonesia, sehingga probabilitas kebangkrutan dana pensiun terhindar dari bias yang terlalu optimistis.

Evidence: Visualisasi scatter plot membedakan titik normal (biru) dan outlier (merah) yang berada di luar garis batas (*threshold*) IQR.



Gambar 7. Penanganan outliers IHSG monthly return

3.2 Feature Engineering

Fitur baru yang dibuat:

Nama Fitur Baru	Formula / Logika	Alasan Pembuatan	Contoh Nilai
inflation_mom_pct	$\text{pct_change}(1) * 100$ pada Indeks IHK	Mengukur inflasi bulanan (<i>Month-on-Month</i>) untuk langkah model simulasi jangka pendek.	+0.21%
inflation_yoy_pct	$\text{pct_change}(12) * 100$ pada Indeks IHK	Target utama kalibrasi parameter jangka panjang (<i>theta</i>) pada model inflasi Ornstein-Uhlenbeck (OU).	+2.84%
growth_normal	Kemiringan (<i>slope</i>) dari regresi log-linear (tanpa menyertakan anomali COVID)	Mengestimasi laju pertumbuhan kenaikan gaji riil tahunan yang stabil dan berjangka panjang.	0.0363 (3.63%/thn)
growth_with_covid	<i>Compound Annual Growth Rate</i> (CAGR) dari keseluruhan tahun data	Mengestimasi pertumbuhan gaji dalam skenario terburuk (menyertakan perlambatan akibat pandemi).	0.0471 (4.71%/thn)
ae_avg_male/ ae_avg_female	Mean(A/E Ratio 2018, 2019, 2021, 2022) per usia	Koreksi pengali tabel mortalitas standar (q_x) pasca-COVID agar sesuai dengan realitas mortalitas di Indonesia.	1.12 (laki-laki usia 30) 0.98 (perempuan usia 30)
multiplier_median	Median(YoY Sektoral / YoY Umum) (tanpa periode COVID)	Mengestimasi faktor pengali sektoral yang stabil terhadap laju inflasi umum.	1.35 (sektor makanan)
return_mom_pct	$\text{pct_change}(1) * 100$ pada harga penutupan bulanan IHSG	Kalibrasi return bulanan dan standar deviasi aset saham untuk simulasi investasi.	+1.2%

return_yoy_pct	pct_change(12) * 100 pada harga penutupan bulanan IHSG	Kalibrasi parameter return tahunan jangka panjang pasar modal Indonesia.	+14.5%
Year, Month, Quarter	Mengekstrak komponen tanggal dari indeks waktu	Menangkap pola musiman bulanan (<i>seasonality</i>), tren tahunan, atau efek kuartalan.	2024 (Year), 2 (Month), 1 (Quarter)
Inflasi_Lag_1 s/d 12	shift(lag) untuk lag 1, 2, 3, 6, dan 12 bulan	Menyediakan informasi historis nilai inflasi pada bulan-bulan sebelumnya sebagai prediktor autokorelasi.	+3.05% (pada Lag 1)
Inflasi_RollMean_ 3 s/d 12	rolling(window).mean() untuk 3, 6, dan 12 bulan	Menghilangkan <i>noise</i> jangka pendek untuk melihat arah pergerakan tren jangka pendek hingga panjang.	+2.90% (RollMean 3)
Inflasi_RollStd_3 s/d 12	rolling(window).std() untuk 3, 6, dan 12 bulan	Mengukur tingkat volatilitas dan ketidakpastian inflasi dalam periode waktu tertentu.	0.15% (RollStd 3)
Inflasi_Diff_1	Selisih inflasi 1 bulan lalu vs 2 bulan lalu	Menggambarkan momentum atau tingkat percepatan/perlambatan inflasi bulanan.	+0.05%
Inflasi_Diff_12	Selisih inflasi 1 bulan lalu vs 13 bulan lalu	Menggambarkan percepatan/perlambatan inflasi tahunan.	-0.20%
Trend	Tahun - Tahun.min()	Representasi numerik linear dari pergerakan waktu jangka panjang (tren waktu).	10 (jika data dimulai dari 2015, dan tahun aktif adalah 2025)

Lag1, Lag2, Lag3	groupby('Daerah')['IHK'].shift(lag) untuk lag 1, 2, dan 3 tahun	Memprediksi IHK tahun depan menggunakan nilai IHK historis di daerah yang sama pada tahun-tahun sebelumnya.	115.4 (pada Lag 1)
Diff1	groupby('Daerah')['IHK'].diff(1)	Mengukur selisih perubahan absolut indeks IHK dibanding tahun lalu per daerah.	+2.3
Growth_%	groupby('Daerah')['IHK'].pct_change() * 100	Mengukur laju pertumbuhan relatif IHK per daerah dibanding tahun sebelumnya.	+2.15%
RollingMean3	Rata-rata bergerak 3 tahunan IHK daerah	Mengurangi fluktuasi jangka pendek untuk menstabilkan prediksi tren harga daerah.	112.5
RollingSTD3	Standar deviasi bergerak 3 tahunan IHK daerah	Mengukur volatilitas pergerakan harga komoditas spesifik di suatu daerah.	1.45
ExpandingMean	Rata-rata kumulatif IHK daerah sejak awal pencatatan	Menangkap nilai rata-rata historis jangka sangat panjang per daerah untuk referensi dasar.	105.8

3.4 Encoding & Transformasi

No	Teknik	Variabel Target	Metode	Alasan
1	Wide-to-Long Melting	IHK per daerah, Gaji per sektor	pd.melt(id_vars, var_name, value_name) untuk merotasi kolom tahun horizontal menjadi baris vertikal.	Mengubah format lebar (<i>wide</i>) bawaan BPS menjadi format panjang (<i>long</i>) yang sesuai untuk analisis runtun waktu (<i>time-series</i>).

2	Winsorization (Clipping Outliers)	IHK per daerah, Gaji per sektor	Membatasi nilai ekstrim menggunakan np.clip (batas persentil 10-90) untuk IHK daerah, dan np.where (batas IQR: $Q1 - 1.5 \cdot IQR$ s.d. $Q3 + 1.5 \cdot IQR$) untuk Gaji sektor.	Membatasi pengaruh pencilan (<i>outliers</i>) ekstrim dari data daerah atau sektor tertentu agar tidak merusak estimasi regresi dan rata-rata pertumbuhan.
3	Median Imputation	Nilai kosong/NaN pada IHK dan Gaji	fillna(median) menggunakan median keseluruhan data untuk IHK daerah, dan median per kolom tahun untuk Gaji sektor.	Mencegah hilangnya baris pengamatan penting akibat nilai kosong, dengan bias yang lebih minimal jika dibandingkan menggunakan nilai mean.
4	Chain-Linking Splice	Indeks IHK (Umum & Sektoral)	Menghitung faktor skala pada titik transisi tahun dasar (Desember 2019 & Desember 2023) untuk melipatgandakan level indeks baru secara kumulatif.	Menghilangkan lompatan deflasi semu hingga -30% akibat pergantian basis tahun dasar periodik dari BPS (2012 to 2018 to 2022).
5	Log-Linear Transformation	Nilai nominal Gaji (Rupiah)	Menghitung logaritma natural (np.log) dari upah historis sebelum melakukan <i>fitting</i> regresi linier.	Mengubah pola pertumbuhan gaji eksponensial di dunia nyata menjadi tren linier agar nilai kemiringan (<i>slope</i>) regresi menjadi stabil.

6	Pembersihan String Angka BPS	Teks angka IHK/Inflasi dari BPS (contoh: "127,52")	Menggunakan ekspresi reguler (<i>Regex</i>) untuk menghapus pemisah ribuan titik, mengganti koma desimal menjadi titik desimal, lalu mengonversi ke float.	Python hanya mengenali titik sebagai penanda desimal, sedangkan format pelaporan lokal Indonesia menggunakan koma.
7	Pembersihan Persentase A/E Ratio	Teks persentase A/E Ratio (contoh: "112%")	Menghapus simbol % lalu membagi nilainya dengan 100 untuk menghasilkan nilai desimal.	Mengubah tipe data teks persentase menjadi format desimal agar dapat dikalikan secara langsung dengan nilai peluang aktuarial (q_x).
8	Penyelarasan Nama Bulan Lokal	Kolom periode tanggal (contoh: "Januari 2020")	Kamus pemetaan untuk menerjemahkan nama bulan Indonesia ke Inggris ('Desember' -> 'December') sebelum melakukan <i>datetime parsing</i> .	Memungkinkan fungsi parser bawaan Pandas (<code>pd.to_datetime</code>) mem-parsing format bulan berbahasa Indonesia menjadi tipe data waktu secara akurat.
9	Kamus Pemetaan Profil Risiko	Profil risiko investasi kategori (Konservatif, Moderat, Agresif)	Lookup langsung ke kamus konfigurasi statis di model simulator untuk memperoleh bobot instrumen saham/obligasi.	Kategori langsung diterjemahkan menjadi parameter numerik simulator finansial, tidak membutuhkan encoding ML konvensional.

10	Interpolasi Linear	Nilai kosong temporal pada indeks IHK nasional dan sektoral	Melakukan pengisian nilai kosong menggunakan <code>.interpolate('linear').ffill()</code> pada data runtun waktu yang telah terurut kronologis.	Mengisi kekosongan data bulanan yang hilang (misalnya pada sektor Makanan akhir tahun 2024) agar perhitungan inflasi bulanan/tahunan tetap kontinu.
----	--------------------	---	--	---

3.5 Splitting Data

Strategi pembagian data disesuaikan dengan jenis model yang dibangun pada tiap-tiap sub-folder:

1. Pendekatan ML Supervised (Domain IHK di `IHK/Feature_IHK.ipynb`)

- Proporsi/Strategi: Pembagian berdasarkan batasan waktu (*Time-Based Hold-Out Split*).
 - Train Set: Data daerah dengan Tahun < 2025.
 - Test Set: Data daerah dengan Tahun >= 2025.
- Alasan: Mencegah terjadinya kebocoran informasi masa depan (data *leakage*) ke masa lalu. Model dilatih dengan data historis sebelum 2025 dan diuji pada data aktual tahun 2025.

2. Pendekatan Deret Waktu Tradisional (Domain Inflasi di `Inflasi`)

- Proporsi/Strategi: Diurutkan secara kronologis berdasarkan kolom Tanggal sebelum dilakukan pemodelan sekuensial (ARIMA atau LSTM).

3. Pendekatan Stokastik & Aktuaria (Domain Utama di `eda_dan_data_preparation.ipynb`)

- Proporsi/Strategi: Pembagian kronologis berbasis karakteristik makroekonomi:
 - 2016 – Des 2019: Fase baseline (normal ekonomi).
 - Feb 2020 – Jul 2021: Fase dibuang (*excluded*) dari inflasi karena anomali COVID-19.
 - Agu 2021 – Des 2025: Fase pemulihan ekonomi (*recovery*).
- Alasan: Model OU sensitif terhadap fluktuasi syok temporer. Membuang periode COVID-19 dan tahun awal backfill BPS menjaga estimasi parameter *theta* dan *kappa* tetap berada di nilai wajarnya.

BAB 4 – PEMODELAN (MODELING)

4.1 A/B Testing

1. Pendefinisian Dua Strategi (A vs B)

Pengujian membandingkan dua pendekatan penempatan portofolio investasi paska pensiun:

- Strategi A (*Fixed Allocation*): Fase deakumulasi tetap mempertahankan profil risiko asal yang dipilih pengguna saat masa produktif.
- Strategi B (*Adaptive Glide Path*): Fase deakumulasi menurunkan profil risiko investasi pengguna secara adaptif sebesar satu tingkat lebih aman. Hal ini dilakukan untuk melindungi nilai modal dari volatilitas pasar ketika dana mulai ditarik rutin.

Kedua strategi ini diuji secara berpasangan dengan modal awal pensiun (*fund_base*) dan jalur inflasi acak yang sama persis (identik) dari hasil fase akumulasi produktif.

2. Rumusan Hipotesis Statistik

Pengujian statistik disusun dengan hipotesis sebagai berikut:

- Hipotesis Nol (H_0): Strategi Adaptive Glide Path (B) tidak memberikan risiko kehabisan dana (ruin probability) yang lebih rendah secara signifikan dibandingkan dengan Strategi Fixed Allocation (A).
- Hipotesis Alternatif (H_1): Strategi Adaptive Glide Path (B) menghasilkan risiko kehabisan dana (ruin probability) yang lebih rendah secara signifikan dibandingkan dengan Strategi Fixed Allocation (A).

3. Metode Pengujian: Wilcoxon Signed-Rank Test

Uji statistik yang digunakan adalah Wilcoxon Signed-Rank Test (paired, one-sided/greater) dari pustaka `scipy.stats`.

- Mengapa Wilcoxon? Pengujian ini dipilih karena data bersifat non-parametrik dan berpasangan (paired). Karena setiap simulasi Monte Carlo (dari 10.000 iterasi) menggunakan deret waktu return dan inflasi yang identik, perbandingan performa kehabisan dana (ruin flag bernilai 1 jika habis, 0 jika bertahan) dari kedua strategi dapat disandingkan secara langsung per iterasi.
- Proses Pengurangan: Selisih risiko dihitung dengan mengurangi bendera bangkrut Strategi A dengan Strategi B ($\text{ruin_A_float} - \text{ruin_B_float}$). Hasil selisih yang positif menandakan Strategi B berhasil menyelamatkan dana dari kebangkrutan di iterasi tersebut sedangkan Strategi A gagal. Akan tetapi kami akan menggunakan strategi A karena lebih konsisten terhadap *profile risk*, sedangkan strategi B sangat menurunkan *profile risk* yang membuat setiap kasus cenderung memiliki risiko relatif kecil.

BAB 5 – EVALUASI

5.1 Limitasi & Risiko

Uraian keterbatasan analisis model ini dan risiko yang perlu dipertimbangkan saat diimplementasikan ke dalam keputusan finansial dunia nyata:

1. Asumsi Kinerja Masa Lalu (Historical Bias): Parameter stokastik investasi (Mean, Volatility, Covariance) didasarkan murni pada kinerja historis IHSG dan Obligasi Pemerintah 10 Tahun (2010–2025). Kinerja historis ini bukanlah jaminan kinerja di masa depan. Perubahan fundamental pada struktur ekonomi makro Indonesia atau shock geopolitik global yang belum pernah terjadi dapat menghasilkan lintasan (path) yang jauh lebih ekstrem dari distribusi historis.
2. Keterbatasan Tabel Mortalitas (Populasi General vs Spesifik): Basis probabilitas kematian (qx) menggunakan populasi umum pekerja formal dari data BPJS. Model tidak menyertakan penyesuaian genetik, komorbid, profil perokok, atau tingkat socioeconomic spesifik individu pengguna yang dapat menggeser harapan hidup (ex) riil mereka lebih panjang atau lebih pendek dari kurva TMPI.
3. Faktor Pajak dan Biaya Transaksi: Simulasi berjalan dalam lingkup return gross/net-implied sederhana dan tidak memodelkan secara granular gesekan biaya riil (frictions) seperti pajak final obligasi, dividen, biaya brokerage fee (transaksi saham), dan expense ratio dari reksa dana/ETF. Hal ini membawa risiko bahwa akumulasi dana real-world bisa sedikit lebih rendah dari kalkulasi komputasional.

BAB 6 – KESIMPULAN

6.1 Kesimpulan

Proyek CuanSelor berhasil dibangun dengan sebuah sistem proyeksi keuangan pensiun yang sangat kuat dan representatif terhadap kondisi riil di Indonesia melalui pembersihan data BPS, JKN, dan pasar modal menggunakan teknik *chain-linking*, *winsorization*, serta *interpolasi linier*. Sistem ini mengintegrasikan pemodelan stokastik inflasi Ornstein-Uhlenbeck, simulasi portofolio Monte Carlo sebanyak 10.000 iterasi, penyesuaian aktuarial harapan hidup riil berbasis rasio Actual-to-Expected (A/E) JKN 2023, uji hipotesis alokasi aset Wilcoxon Signed-Rank, dan stress testing krisis makro ekonomi untuk menghasilkan perencanaan dana pensiun yang tahan uji terhadap guncangan pasar dan inflasi sektoral. Dengan demikian, luaran data terstruktur berupa keputusan alokasi portofolio Glide Path yang dihasilkan dari kalkulator utama siap diintegrasikan sebagai mesin kecerdasan kalkulator keuangan yang andal dan berbasis bukti ilmiah (*evidence-based*).